Đề cương Project cuối kỳ – Nhóm 4

Thông tin chung

Nhóm 4 xây dựng một hệ thống thu thập tin cho thuê từ nhiều nguồn, dùng NLP để lọc ra tin chính chủ và tự động đưa vào CRM. Hệ thống được chạy thử trên thị trường cho thuê Hà Nội.

Mục	Nội dung
Tên đề tài	Xây dựng Hệ thống Thông minh Thu thập, Bóc tách Dữ liệu và Tự động hóa CRM Quản lý Chủ nhà Cho thuê từ Đa Nguồn (Chợ Tốt, Facebook, Batdongsan)
Nhóm	Nhóm 4
Người dùng mục tiêu	Môi giới cho thuê cá nhân và nhóm môi giới nhỏ (2–10 người)
Phạm vi thí điểm	Hà Nội; nhà nguyên căn, chung cư, phòng trọ cho thuê
Mức tư duy theo yêu cầu TH4	Phân tích (mục 2), Đánh giá (mục 3), Sáng tạo (mục 4 và 5)

1. Xác định vấn đề thực tế

Vấn đề được chọn: môi giới cho thuê tốn nhiều giờ mỗi ngày để lọc thủ công tin đăng trên nhiều kênh, nhưng vẫn gọi nhầm môi giới khác và bỏ lỡ chủ nhà thật. Nguyên nhân là không có công cụ nào gom, làm sạch và xác minh nguồn hàng.

Bối cảnh. Với môi giới cho thuê, nguồn hàng là danh sách chủ nhà chính chủ có nhà trống, và đây là tài sản cạnh tranh chính của họ. Tin đăng lại nằm rải rác trên Chợ Tốt, Batdongsan.com.vn, Alonhadat và hàng trăm nhóm Facebook. Tin viết dạng văn bản tự do, và cùng một căn nhà thường bị đăng lại nhiều lần bởi nhiều người khác nhau.

Pain point cụ thể của môi giới:

- Phải mở từng kênh, đọc từng tin rồi chép tay sang Excel hoặc Zalo.
- Nhãn "chính chủ" bị lạm dụng, nên nhiều cuộc gọi đi đến tay một môi giới khác.
- Một chủ nhà xuất hiện ở nhiều tin và nhiều kênh, dẫn đến gọi trùng và ghi chú rời rạc.

- Không đo được hiệu suất: đã tiếp cận bao nhiêu chủ nhà, bao nhiêu người ký gửi, khu vực nào đang dư nguồn cung.

Phát biểu vấn đề. Làm thế nào để môi giới nhận được danh sách chủ nhà chính chủ đã được xác minh sơ bộ, không trùng lặp, có thông tin có cấu trúc, trong vòng vài giờ sau khi tin được đăng, mà không vi phạm điều khoản của nền tảng và quy định về bảo vệ dữ liệu cá nhân?

Phạm vi:

Trong phạm vi	Ngoài phạm vi
Tin công khai trên Phongtro123, Phongtro.vn, Chợ Tốt (Alonhadat dự phòng)	Định giá bất động sản, ký hợp đồng, thanh toán
Bài trong nhóm Facebook công khai, thu thập bán tự động (mục 4)	Crawl nhóm Facebook kín, đăng nhập bằng tài khoản giả
Tin tiếng Việt, khu vực Hà Nội	Gửi tin nhắn hoặc gọi điện tự động hàng loạt tới chủ nhà
CRM web cho một nhóm môi giới, dashboard BI	Ứng dụng di động, đa thành phố

Câu hỏi nghiên cứu:

1. RQ1: Kết hợp nội dung tin với hành vi đăng tin (tần suất số điện thoại, số khu vực đăng) giúp phân biệt chính chủ và môi giới chính xác hơn bao nhiêu so với chỉ dùng nội dung?
2. RQ2: Rule/regex, PhoBERT tinh chỉnh và LLM đánh đổi nhau thế nào về độ chính xác trích xuất, tốc độ và chi phí trên mỗi 1.000 tin?
3. RQ3: So với cách làm thủ công, hệ thống rút ngắn thời gian tìm được một lead chính chủ hợp lệ bao nhiêu? (đo thực nghiệm khi chạy thử, không đặt con số trước)

2. Phân tích nguyên nhân, hậu quả và yếu tố ảnh hưởng

Vấn đề không chỉ là thiếu một công cụ crawl. Gốc rễ nằm ở ba tầng: dữ liệu phi cấu trúc và phân tán, thị trường có động cơ đăng tin sai lệch, và quy trình làm việc thủ công. Vì vậy giải pháp phải xử lý cả ba, không chỉ tầng thu thập.

Nguyên nhân (cây vấn đề):

1. Tầng dữ liệu
    - Tin nằm rải rác trên nhiều kênh, mỗi kênh một định dạng, và không có mã định danh chung cho một căn nhà hay một chủ nhà.
    - Văn bản tự do, viết tắt và không dấu ("2pn", "7tr5", "ccmn", "chdv"). Số điện thoại thường bị viết tách hoặc năm trong ảnh để né bộ lọc.
    - Địa chỉ không chuẩn hóa. Sau đợt sắp xếp đơn vị hành chính năm 2025, tin cũ dùng tên quận cũ còn tin mới dùng tên phường mới.
2. Tầng thị trường
    - Môi giới có động cơ tự nhận là "chính chủ" để được gọi nhiều hơn, nên chính nhãn này không còn đáng tin.
    - Có tin ảo hoặc tin mồi giá thấp để lấy số khách, và tin đã cho thuê xong nhưng không được gỡ.
3. Tầng công cụ và quy trình
    - Các nền tảng đăng tin không có bộ lọc chính chủ đáng tin. CRM phổ thông thì không có đầu vào tự động từ tin rao.
    - Môi giới copy-paste sang Excel hoặc Zalo, nên không có lịch sử chăm sóc và không đo được kết quả.

Hậu quả:

- Với môi giới: mất thời gian, gọi nhầm môi giới khác, và bỏ lỡ những căn tốt vốn được thuê nhanh.
- Với nhóm hoặc công ty: dữ liệu nằm trong máy từng người, mất khi nhân sự nghỉ, quản lý không đo được hiệu suất.
- Với chủ nhà: bị nhiều người gọi trùng, dẫn đến khó chịu và từ chối hợp tác.
- Rủi ro pháp lý: lưu và chia sẻ tên, số điện thoại tràn lan, không có kiểm soát.

Yếu tố ảnh hưởng đến dự án:

Nhóm yếu tố	Biểu hiện	Ảnh hưởng tới thiết kế
Pháp lý	Luật Bảo vệ dữ liệu cá nhân 2025 (số 91/2025/QH15) có hiệu lực từ 01/01/2026. Luật yêu cầu chủ thể dữ liệu đồng ý trước khi thu thập, trừ trường hợp luật quy định khác, và cấm mua bán dữ liệu cá nhân (LSVN, VnEconomy)	Thu thập tối thiểu, có thời hạn lưu, có cơ chế xóa theo yêu cầu, không bán hay chia sẻ danh sách

Nhóm yếu tố	Biểu hiện	Ảnh hưởng tới thiết kế
Điều khoản nền tảng	Facebook cấm thu thập tự động. Các trang rao vặt có giới hạn tần suất và điều khoản sử dụng riêng. Nghị định 363/2026/NĐ-CP (hiệu lực 11/11/2026) phạt 40–60 triệu đồng với cá nhân dùng công cụ tự động thu thập dữ liệu trái phép	Không bot hóa Facebook; với các trang khác, crawl lịch sự (độ trễ 3–5 giây, tôn trọng robots.txt, User-Agent ghi rõ mục đích học thuật); không vượt captcha, đăng nhập hay Cloudflare
Kỹ thuật	Chống crawl (captcha, JS động), giao diện HTML thay đổi	Tách lớp parser theo nguồn, có giám sát lỗi và cảnh báo khi parser hỏng
Ngôn ngữ	Tiếng Việt không dấu, viết tắt, teencode	Cần bước chuẩn hóa văn bản trước NER; đánh giá trên dữ liệu thật, không trên dữ liệu mẫu đẹp
Hành chính	Địa chỉ cũ và mới cùng tồn tại	Cần bảng ánh xạ địa chỉ để dashboard theo khu vực không bị sai
Con người	Môi giới quen Zalo và Excel	CRM phải nhanh hơn cách cũ ngay từ ngày đầu; có thể xuất ngược ra Excel
Chi phí	Gemini free tier miễn phí nhưng giới hạn số request mỗi phút và mỗi ngày, mức giới hạn thay đổi thường xuyên	Chỉ gọi Gemini cho tin mà rule/model nhỏ không chắc chắn (mục 4); có hàng đợi và tự lùi lại khi gặp lỗi 429

3. Đánh giá các giải pháp hiện có

Chưa giải pháp nào làm được đồng thời ba việc: xác minh chính chủ dựa trên hành vi đăng tin, gộp một chủ nhà xuất hiện trên nhiều nguồn, và tuân thủ quy định dữ liệu cá nhân. Đây chính là khoảng trống mà dự án nhắm tới.

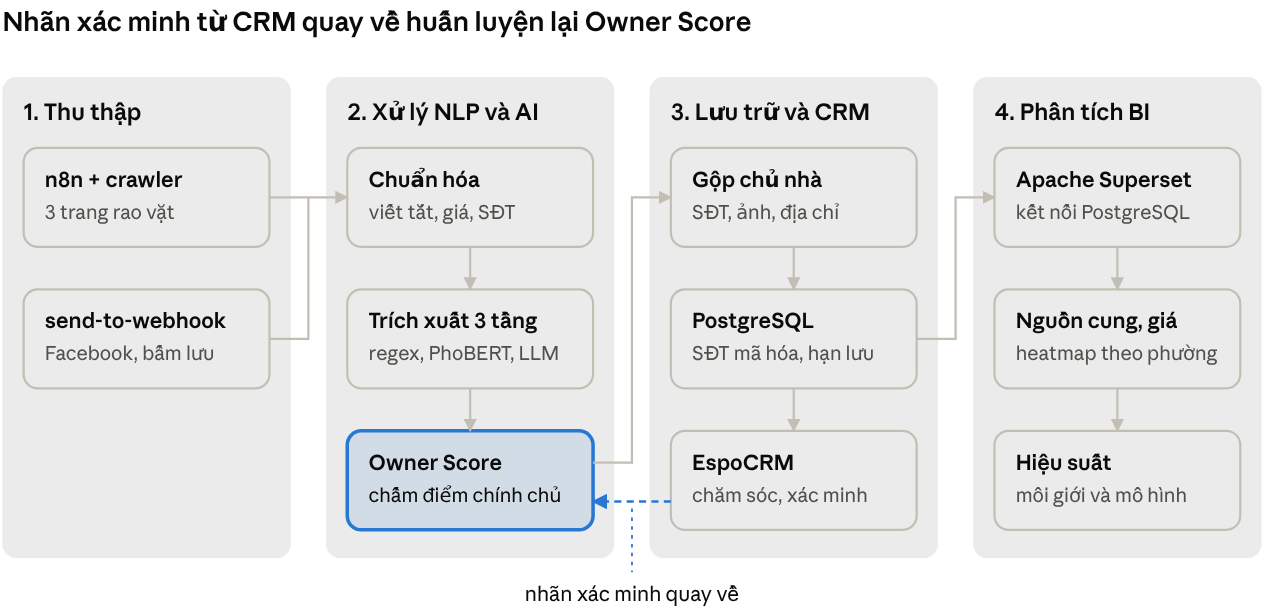
Giải pháp	Ưu điểm	Nhược điểm	Bài học cho dự án
Lọc thủ công, lưu bằng Excel hoặc Zalo	Không tốn chi phí; môi giới tự đánh giá được độ tin cậy	Chậm, không mở rộng được; trùng lặp; dữ liệu nằm trong máy cá nhân	Thời gian thao tác thủ công là mốc so sánh (baseline) cho RQ3
Bộ lọc có sẵn của từng nền tảng (nhãn cá nhân/chuyên nghiệp, lọc theo giá và khu vực)	Có sẵn, miễn phí, dễ dùng	Nhãn do người đăng tự khai; chỉ trong một kênh; không gộp chủ nhà giữa các kênh	Không thể tin vào nhãn tự khai; cần tín hiệu khách quan như tần suất số điện thoại
Mua danh sách chủ nhà hoặc dữ liệu số điện thoại trôi nổi	Nhanh, có ngay số lượng lớn	Dữ liệu cũ, sai nhiều; mua bán dữ liệu cá nhân bị Luật 91/2025/QH15 cấm	Loại bỏ hoàn toàn; hệ thống không được trở thành kho dữ liệu để bán lại
CRM phổ thông (Odoo CRM, ERPNext, HubSpot bản miễn phí)	Quy trình lead đầy đủ, ổn định, có sẵn báo cáo	Không có đầu vào tự động từ tin rao; không hiểu tiếng Việt viết tắt; tùy biến tốn công	Dùng luôn EspoCRM (mã nguồn mở) làm CRM; chỉ tự xây phần nhập liệu tự động và xác minh
Trích xuất bằng rule/regex	Nhanh, rẻ, dễ giải thích	Gãy khi gặp cách viết mới; khó tách tên người và loại hình nhà	Dùng làm lớp đầu tiên cho trường dễ (số điện thoại, giá, diện tích)
PhoBERT tinh chỉnh cho NER và phân loại	Chính xác cao trên tiếng Việt; chạy cục bộ, không tốn phí theo tin	Cần dữ liệu gán nhãn (hàng trăm đến hàng nghìn tin); tốn công huấn luyện	Phù hợp nếu nhóm có thời gian gán nhãn; dùng làm phương án so sánh
Gọi LLM (Gemini, OpenAI hoặc Ollama) cho mọi tin	Không cần huấn luyện; trả JSON trực tiếp; hiểu tốt văn bản lộn xộn	Chi phí tăng theo số tin; có thể bịa trường thiếu; chậm; phải gửi dữ liệu cá nhân ra API bên ngoài	Chỉ gọi khi cần, kiểm tra kết quả bằng rule, dùng Gemini free tier và che dữ liệu cá nhân trước khi gửi

Nhìn lại bản nháp ban đầu của nhóm. Bản nháp có hướng đi tốt nhưng còn bốn điểm yếu cần sửa:

- Phân loại chính chủ chủ yếu dựa vào từ khóa như "cắt lỗ" hay "hỗ trợ vay ngân hàng". Đây là từ khóa của tin bán, không phải tin cho thuê, và môi giới rất dễ né từ khóa.
- Mục tiêu crawl Facebook hoàn toàn tự động 24/7 vi phạm điều khoản của nền tảng. Tài khoản dễ bị khóa, nên đây là điểm yếu nhất về tính khả thi.
- Các con số "chính xác trên 80%" và "giảm 90% thời gian" chưa có cách đo hay tập dữ liệu kiểm thử đi kèm.
- Bản nháp chưa đề cập dữ liệu cá nhân, dù sản phẩm của hệ thống chính là hồ sơ tên và số điện thoại.

4. Giải pháp đề xuất

Nhóm giữ khung 4 module của bản nháp nhưng thêm năm cải tiến. Cải tiến lớn nhất là xác định chính chủ dựa trên hành vi đăng tin (Owner Score) thay vì từ khóa, và kết quả xác minh trong CRM được đưa ngược lại để mô hình học tiếp.



kiến trúc hệ thống · 4 module, 1 vòng phản hồi

Dữ liệu chạy từ trái sang phải. Đường đứt nét là vòng học: kết quả môi giới xác minh trong CRM quay lại cải thiện Owner Score.

Nguồn dữ liệu và cách thu thập

Nguồn	Dữ liệu lấy	Cách lấy
Chợ Tốt (chotot.com)	Tiêu đề, mô tả, giá, diện tích, loại hình, phường mới, tọa độ, ảnh, ngày đăng, ID người đăng, số tin đang đăng, nhãn môi giới (company_ad). Số điện thoại bị che 4 số cuối; không lấy số đầy đủ vì cần đăng nhập	Gọi API JSON công khai gateway.chotot.com bằng n8n, khoảng 1 request/giây. Vai trò: nguồn tín hiệu cho Owner Score và dữ liệu giá thị trường, không tạo lead trực tiếp; môi giới tự xem số trên Chợ Tốt
Alonhadat (dự phòng)	Đủ trường kể cả tên và số điện thoại; có cả địa chỉ cũ và mới (dùng được để kiểm tra bảng ánh xạ địa chỉ)	Crawl4AI hoặc Scrapy đọc microdata schema.org. Trang giới hạn tần suất (HTTP 429) sau khoảng 20 tin, nên chỉ chạy ⩽ 20 tin/lượt, giãn ⩾ 10 giây và dừng hẳn khi gặp 429
Phongtro123.com	Phòng trọ, căn hộ mini, căn hộ dịch vụ, nhà nguyên căn. Trang danh mục có sẵn JSON-LD gồm địa chỉ (theo phường mới), giá và số điện thoại	Scrapy hoặc n8n đọc JSON-LD trên trang danh mục (20 tin/trang, không cần mở chi tiết); chỉ mở trang chi tiết cho một phần tin để lấy tên, ID và số tin của người đăng
Phongtro.vn	Phòng trọ, căn hộ studio, căn hộ dịch vụ. Trang chi tiết có tên, ID và số điện thoại người đăng, giá, diện tích, địa chỉ theo phường mới	Lấy danh sách URL qua sitemap (trang danh mục không phân trang được), mỗi tin 1 request đọc dữ liệu Next.js của trang chi tiết; robots.txt cho phép bot thông thường
Nhóm Facebook công khai	Nội dung bài, ảnh, tên người đăng, link bài	Extension mã nguồn mở send-to-webhook: môi giới bôi đen bài, chuột phải gửi về webhook n8n

Mọi tin, dù từ nguồn nào, đều đi qua cùng một pipeline xử lý (các cải tiến 1, 2 và 4 bên dưới) trước khi vào CRM. Danh sách nguồn trên đã được chốt sau khi nhóm chạy thử thu thập trên 6 trang (kết quả ở bảng dưới). Guland, Homedy, Rever, Cafeland không được thử vì

chủ yếu là tin môi giới, tin dự án hoặc tin bán.

Kết quả chạy thử nguồn dữ liệu

Nhóm chạy thử mỗi nguồn khoảng 100 tin, tuân thủ đúng quy tắc ở mục 2. Phongtro123 và Phongtro.vn là hai nguồn tạo lead chính vì có số điện thoại đầy đủ; Chợ Tốt không có số đầy đủ nhưng cho tín hiệu tốt nhất cho Owner Score.

Nguồn	Kết quả	Request/tin	SĐT đầy đủ	Tín hiệu cho Owner Score	Quyết định
Phongtro123	100 tin, không lỗi	0,6	100%	Tên, ID người đăng, số tin đăng (một phần tin)	Giữ, nguồn lead chính
Phongtro.vn	100 tin, không lỗi	1,0	100%	Tên, ID người đăng	Giữ, nguồn lead chính
Chợ Tốt	99 tin, không lỗi	1,0	0% (bị che)	ID người đăng, số tin đang đăng, nhãn company_ad (50/99 tin là môi giới)	Giữ cho Owner Score và giá
Alonhadat	Bị 429 ngay đầu	–	Có (khi lấy được)	Tên, link trang thành viên, số tin	Dự phòng
Batdongsan	403 + Cloudflare	–	–	–	Bỏ (không vượt Cloudflare)
Muaban	100 tin, không lỗi	0,1	8% (tự ghi trong mô tả)	ID người đăng, cờ is_company	Bỏ (số bị che và mã hóa)

Trong mẫu, chỉ 4 trên 171 số điện thoại xuất hiện ở từ 2 nguồn trở lên. Phongtro123 chỉ có diện tích ở 48% tin, nên bộ trích xuất phải lấy thêm diện tích từ phần mô tả.

Cải tiến 1: Owner Score, chấm điểm chính chủ theo hành vi

Mỗi số điện thoại được chấm từ 0 đến 100, kèm lý do, dựa trên các đặc trưng sau:

- Số tin cùng số điện thoại trong 30 ngày, số khu vực khác nhau và số loại hình nhà khác nhau. Với Chợ Tốt, số điện thoại bị che nên dùng ID người đăng và số tin đang đăng (live_ads) thay cho số điện thoại; trong mẫu chạy thử, 31% tin Chợ Tốt thuộc người đăng có từ 5 tin trở lên.
- Mức độ giống nhau về văn bản giữa các tin (tin môi giới thường dùng chung một mẫu).
- Ảnh trùng với tin của số điện thoại khác, so bằng perceptual hash.

- Tín hiệu ngôn ngữ của tin cho thuê như "miễn trung gian", "nhận ký gửi", "nhiều căn", "phí môi giới", cùng nhãn tự khai của nền tảng, ví dụ cờ company_ad (tin "Bán chuyên/Môi giới") trong dữ liệu Chợ Tốt (chỉ là đặc trưng phụ và nhãn yếu ban đầu).

Mô hình là Logistic Regression hoặc LightGBM, đủ đơn giản để giải thích được vì sao một số bị chấm thấp. Ngưỡng phân loại ban đầu: từ 70 trở lên là chính chủ, 40–69 cần xác minh, dưới 40 là môi giới. Riêng tin phòng trọ, mô hình tách thêm hai nhóm không phải chủ nhà cũng không phải môi giới: người thuê "pass phòng" hoặc tìm người ở ghép (nhận diện bằng từ khóa "pass", "ở ghép", "share"), và đơn vị vận hành chung cư mini hoặc căn hộ dịch vụ đăng nhiều tin. Các ngưỡng điểm nói trên sẽ được hiệu chỉnh lại trên tập validation.

Lập luận: Ngôn từ thì dễ giả, còn hành vi thì khó. Môi giới cần nhiều nguồn hàng nên số điện thoại của họ buộc phải xuất hiện ở nhiều tin và nhiều khu vực. Đây là cái giá kinh tế mà họ không né được. Ngoài ra, mỗi lần môi giới gọi và đánh dấu "đây là môi giới" trong CRM, nhãn đó được lưu lại để huấn luyện mô hình định kỳ (vòng học chủ động).

Cải tiến 2: Trích xuất phân tầng, chỉ gọi LLM khi cần

1. Tầng 1, chuẩn hóa và regex: đổi "7tr5" thành 7.500.000, "2pn" thành 2 phòng ngủ, ghép số điện thoại bị viết tách rồi chuẩn hóa bằng thư viện phonenumbers; trích giá, diện tích, số điện thoại.
2. Tầng 2, NER tiếng Việt bằng underthesea hoặc PhoBERT tinh chỉnh: trích tên, địa chỉ, loại hình.
3. Tầng 3, Gemini API bản miễn phí (model Flash hoặc Flash-Lite) ở chế độ trả JSON theo schema, kết hợp thư viện instructor: chỉ dùng cho tin còn thiếu trường hoặc có độ tin cậy thấp. Số điện thoại và tên được che trước khi gửi lên API.
4. Kiểm tra cuối: JSON phải đúng schema Pydantic, và mọi giá trị trích ra phải tìm thấy trong văn bản gốc. Bước này chống việc LLM tự bịa ra thông tin.

Lập luận: Phần lớn trường thông tin có thể lấy bằng rule với chi phí gần bằng 0. Gemini chỉ xử lý phần khó, nên ít khi chạm giới hạn số request mỗi ngày của bản miễn phí. Dữ liệu gửi qua bản miễn phí có thể được Google dùng để cải thiện sản phẩm, nên bắt buộc che số điện thoại và tên trước khi gửi. Tỉ lệ tin phải dùng đến tầng 3 là một chỉ số đo cho RQ2.

Cải tiến 3: Thu thập Facebook bán tự động

Thay vì bot crawl 24/7, nhóm dùng extension mã nguồn mở send-to-webhook (giấy phép MIT), không phải tự viết. Khi đọc bài trong nhóm công khai, môi giới bôi đen nội dung, chuột phải và gửi về webhook của n8n để đưa vào pipeline. Ba trang rao vặt được thu thập

theo lịch do n8n điều phối (xem bảng nguồn dữ liệu), ở tần suất thấp và tôn trọng robots.txt.

Lập luận: Phương án này mất tính "24/7" với Facebook, nhưng đổi lại hợp lệ với điều khoản nền tảng, không bị khóa tài khoản và bền vững. Facebook cũng vẫn đóng góp dữ liệu cho Owner Score.

Cải tiến 4: Gộp chủ nhà và căn nhà

- Gộp cứng theo số điện thoại đã chuẩn hóa: một chủ nhà có nhiều tin đăng.
- Gộp mềm theo địa chỉ, diện tích và ảnh (dùng sãn datasketch MinHash cho văn bản, imagehash cho ảnh, Splink cho ghép bản ghi) để phát hiện một căn bị nhiều số điện thoại khác nhau đăng. Hiện tượng này thường là dấu hiệu của môi giới, nên nó cũng được đưa vào Owner Score.
- Tin bị gỡ khỏi nguồn được tự động đánh dấu "có thể đã cho thuê". Địa chỉ cũ được đổi sang phường mới bằng thư viện vietnamadminunits.

Cải tiến 5: Bảo vệ dữ liệu ngay từ thiết kế

- Chỉ lưu các trường cần cho việc liên hệ. Mỗi hồ sơ ghi rõ nguồn và thời điểm thu thập.
- Số điện thoại được mã hóa trong cơ sở dữ liệu (pgcrypto); dữ liệu dùng cho phân tích và dashboard chỉ lưu bản băm (hash) của số. Số chỉ hiện đầy đủ khi môi giới bấm "Liên hệ", và mỗi lần xem đều được ghi log.
- Lead không chuyển đổi được tự xóa sau 90 ngày bằng một workflow n8n chạy hăng đêm. Có nút xóa ngay khi chủ nhà yêu cầu.
- Không có chức năng xuất hàng loạt số điện thoại.

Nhóm không phải chuyên gia pháp lý. Cơ sở pháp lý cho việc xử lý dữ liệu do chủ nhà tự công khai sẽ được trao đổi với giảng viên trước khi triển khai thật.

CRM và dashboard

- CRM dùng EspoCRM (mã nguồn mở AGPL-3.0, có giao diện tiếng Việt): trường và trạng thái cấu hình ngay trên giao diện, không cần code; khi môi giới đổi trạng thái, webhook gửi nhãn về để huấn luyện lại Owner Score. Vòng đời lead: Mới → Đang liên hệ → Đã xác minh chính chủ (hoặc Là môi giới, loại) → Đã ký gửi → Đã cho thuê.
- Dashboard trên Superset: heatmap nguồn cung theo phường (ranh giới phường lấy từ bộ GeoJSON mở vietnamese-provinces-database), giá thuê trung vị theo khu vực và loại hình (dùng trung vị thay vì trung bình để tránh tin môi giá làm lệch), hiệu suất từng

môi giới, và độ chính xác của Owner Score theo tuần.

Công cụ có sẵn và phần nhóm tự lập trình

Nguyên tắc: phần nào đã có công cụ miễn phí, mã nguồn mở thì dùng lại; nhóm chỉ lập trình những phần chưa có công cụ nào làm được. Theo khảo sát, công cụ có sẵn phủ được phần lớn hệ thống. Phần tự viết tập trung vào Owner Score, adapter cho từng trang, bộ chuẩn hóa tiếng Việt và phần kết nối.

Thành phần	Công cụ có sẵn (miễn phí)	Phần nhóm tự lập trình
Điều phối, lịch chạy	n8n self-host, Redis	Các workflow nối các bước
Thu thập 3 trang rao vặt (1 dự phòng)	API JSON công khai của Chợ Tốt, Scrapy, sitemap của Phongtro.vn, Crawl4AI cho Alonhadat	Adapter đưa dữ liệu từng trang về schema chung
Thu thập Facebook	Extension send-to-webhook (MIT)	Không cần
Chuẩn hóa, bóc tách	underthesea, phonenumbers, Gemini API (free tier), instructor	Từ điển viết tắt, bộ đọc giá và diện tích, prompt và schema
Địa chỉ	vietnamadminunits, vietnamese-provinces-database (GeoJSON)	Xử lý phường cũ bị chia cho nhiều phường mới
Chống trùng	datasketch, imagehash, Splink	Quy tắc gộp và ngưỡng
Owner Score	scikit-learn hoặc LightGBM	Toàn bộ đặc trưng và mô hình (đóng góp chính của đồ án)
Gán nhãn	Label Studio	Không cần
CRM	EspoCRM (AGPL-3.0, có tiếng Việt)	Gọi API tạo lead, webhook ghi nhãn ngược
Báo cáo BI	Apache Superset, PostGIS	Câu truy vấn cho dashboard
Bảo vệ dữ liệu	pgcrypto, workflow n8n	Mã hóa cột, xóa theo hạn và theo yêu cầu
Triển khai	Docker Compose	File cấu hình

Lưu ý giấy phép: n8n dùng Sustainable Use License, chỉ miễn phí cho mục đích phi thương mại hoặc nội bộ. Điều này phù hợp với đồ án, nhưng nếu thương mại hóa thì phải mua giấy phép. Nhóm không dùng NocoDB vì từ 2026 công cụ này cũng chuyển sang loại giấy phép tương tự.

Phương án thay thế: Twenty CRM nếu muốn giao diện hiện đại hơn; Node-RED (Apache 2.0) nếu muốn tránh giấy phép của n8n.

5. Kế hoạch thực hiện

Dự án được làm theo 6 bước, theo đúng thứ tự dữ liệu đi qua hệ thống: từ thu thập, qua xử lý, đến CRM và báo cáo. Mỗi bước có một sản phẩm đầu ra kiểm tra được.

Các bước thực hiện:

1. Khảo sát và chuẩn bị dữ liệu: thu khoảng 300 tin mẫu, đo thời gian môi giới tìm lead theo cách thủ công (baseline), gán nhãn 500 tin bằng Label Studio, thiết kế CSDL. Đầu ra: tập dữ liệu gán nhãn, sơ đồ CSDL.
2. Dựng module thu thập: cấu hình n8n gọi API Chợ Tốt, chạy crawler cho Phongtro123 và Phongtro.vn (Alonhadat dự phòng), cài extension send-to-webhook cho Facebook. Đầu ra: tin thô được lưu liên tục.
3. Xây dựng module xử lý: chuẩn hóa văn bản, trích xuất 3 tầng, Owner Score. Đầu ra: pipeline chạy thông từ lúc thu thập đến khi lưu CSDL.
4. Cấu hình EspoCRM và nối API: gộp chủ nhà, vòng đời lead, các biện pháp bảo vệ dữ liệu. Đầu ra: môi giới xem và chăm sóc được lead.
5. Cấu hình dashboard Superset. Đầu ra: heatmap nguồn cung, giá trung vị, hiệu suất.
6. Chạy thử và đánh giá: cho 2–3 môi giới dùng thử, thu nhãn xác minh, huấn luyện lại Owner Score, đo theo bảng tiêu chí bên dưới. Đầu ra: báo cáo cuối kỳ và demo.

Phân công cho 3 thành viên (nhóm điền tên thành viên):

Vai trò	Phụ trách	Sản phẩm chính
Thành viên 1: Thu thập và điều phối	Module 1	Workflow n8n, adapter cho từng trang, extension Facebook, job xóa dữ liệu theo hạn
Thành viên 2: NLP và Owner Score	Module 2	Pipeline trích xuất, mô hình chấm điểm, tập gán nhãn
Thành viên 3: Backend, CRM và BI	Module 3, 4	API FastAPI (/extract, /score), CSDL, gộp chủ nhà, mã hóa, cấu hình và nối API EspoCRM, dashboard Superset

Cả ba cùng gán nhãn 500 tin, kiểm thử và viết báo cáo. Một người kiêm trưởng nhóm, theo dõi tiến độ và chuẩn bị demo.

Tiêu chí đánh giá:

Tiêu chí	Cách đo	Ngưỡng đạt
Trích xuất trường dễ	F1 của số điện thoại, giá, diện tích trên tập test 200 tin gán tay	≥ 0,95
Trích xuất trường khó	F1 của địa chỉ, tên, loại hình trên cùng tập test	≥ 0,80
Phân loại chính chủ (RQ1)	Precision của lớp chính chủ trên tập test, so với baseline chỉ dùng từ khóa	≥ 0,80 và cao hơn baseline
Gộp chủ nhà	Tỉ lệ gộp đúng trên 100 cặp hồ sơ kiểm tra tay	≥ 0,90
Chi phí xử lý (RQ2)	Tỉ lệ tin phải dùng đến LLM ở tầng 3	≤ 30%
Độ trễ	Thời gian từ lúc tin xuất hiện trên nguồn đến khi vào CRM	≤ 2 giờ
Hiệu quả thực tế (RQ3)	Số phút để có một lead chính chủ hợp lệ, thủ công so với dùng hệ thống, đo với 2–3 môi giới	Giảm ≥ 50%
Mức độ dễ dùng	Bảng hỏi SUS sau đợt chạy thử	≥ 68 điểm
Tuân thủ dữ liệu	Hồ sơ có ghi nguồn và hạn xóa; checklist bảo vệ dữ liệu	100%

Precision được chọn thay cho accuracy, vì điều môi giới cần nhất là khi hệ thống nói "chính chủ" thì điều đó đúng.

Rủi ro và phương án dự phòng:

Rủi ro	Phương án dự phòng
Trang nguồn chặn (403, 429, Cloudflare) hoặc đổi giao diện	Adapter tách riêng theo nguồn, có cảnh báo khi hỏng; gặp 403 hoặc 429 là dừng nguồn đó, không vượt. Chạy thử cho thấy Batdongsan bị chặn và Alonhadat bị giới hạn, nên hệ thống dựa chính vào Phongtro123, Phongtro.vn, Chợ Tốt và Facebook
Không đủ thời gian gán nhãn để tinh chỉnh PhoBERT	Dùng rule kết hợp LLM; PhoBERT chỉ làm phương án so sánh nếu kịp

Rủi ro	Phương án dự phòng
Gemini free tier hết hạn mức trong ngày hoặc Google đổi giới hạn	Tin chưa xử lý được xếp hàng chờ sang ngày hôm sau; chuyển sang model Flash-Lite có hạn mức cao hơn; tầng 1 và 2 vẫn chạy nên pipeline không dừng
Không tìm được môi giới tham gia chạy thử	Thành viên nhóm đóng vai môi giới, đo trên tập tin đã thu
Rủi ro pháp lý về dữ liệu cá nhân	Chỉ dùng dữ liệu công khai; xóa toàn bộ dữ liệu thật sau khi kết thúc đồ án

Sản phẩm bàn giao: mã nguồn kèm Docker Compose, tập dữ liệu gán nhãn đã ẩn số điện thoại, báo cáo cuối kỳ và video demo.